

La arquitectura de la plataforma de soporte

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · Introducción a modelos generativos y consumo por API

MODALIDAD

Grupal, de 4 a 5 personas, en micro salas durante la sesión sincrónica.

APRENDIZAJE ESPERADO 1

Analizar el rol de los modelos generativos en el desarrollo de aplicaciones, describiendo sus tipos, casos de uso, tecnologías asociadas y representando arquitecturas funcionales que integren estos modelos mediante APIs.

CRITERIOS DE EVALUACIÓN

- 1.1 Clasifica los tipos de modelos generativos identificando sus características y aplicaciones más frecuentes en la organización.
- 1.2 Representa un diagrama funcional de una aplicación con IA generativa, explicando la función de cada componente dentro de la arquitectura.
- 1.3 Analiza la elección de la arquitectura en función de criterios como escalabilidad, seguridad o mantenimiento.

Contexto

Nube Sur (empresa ficticia) vende software de gestión a pymes y tiene una mesa de ayuda que atiende a sus clientes por correo, formulario web y chat.

Problema

La mesa de ayuda recibe unos 5.000 tickets al día. Los agentes pierden tiempo leyendo tickets largos, la prioridad se asigna a ojo y, cuando hay una caída del servicio, llegan cientos de tickets sobre el mismo problema que se atienden uno por uno.

Solución

Una plataforma que use modelos generativos para tres funciones: **resumir** cada ticket, **clasificarlo** por categoría y prioridad, y **agrupar los tickets duplicados** comparando sus embeddings en un *vector store*. En este aprendizaje esperado el equipo diseña su arquitectura; en los siguientes la irá construyendo por partes.

Desarrollo

- 1. Modelos y casos de uso (criterio 1.1).** Para cada una de las tres funciones, indiquen el tipo de modelo generativo que usarían, el caso de uso al que corresponde (por ejemplo, *summarization*) y por qué.

2. Diagrama funcional (criterio 1.2). Dibujen la arquitectura completa con cliente, servidor API, modelo de IA, módulo de preprocesamiento y base de datos o *vector store*. Numeren el flujo de datos de un ticket, desde que llega hasta que el agente ve su resumen, su prioridad y sus duplicados. Marquen dónde se guardan las claves de las APIs.

3. Dos alternativas (criterio 1.3). Comparen en una tabla dos arquitecturas:

- **A:** el servidor llama al modelo en el momento en que llega cada ticket (*request-response*);
- **B:** los tickets entran a una cola y un *pipeline* los procesa por lotes cada pocos minutos.

Evalúen cada una en escalabilidad, seguridad (los tickets traen datos personales de clientes), mantenimiento y costo.

4. Registro de decisión. Escriban en media página la decisión del equipo: qué arquitectura eligen, por qué, qué riesgo aceptan y cómo lo mitigarían.

5. Tecnologías. Asignen a cada componente una tecnología o librería concreta (por ejemplo, OpenAI API, Hugging Face Transformers o LangChain) y justifiquen dos de ellas.

6. Comité de seguridad. Al volver a la sala principal, otro equipo actúa como comité de seguridad y les hace dos preguntas sobre el manejo de datos personales y claves. El portavoz responde.

Roles del equipo

Cada integrante asume un rol, que rota en el ABPRO de cada aprendizaje esperado:

- **Coordinador/a:** cuida el tiempo y que todos participen.
- **Arquitecto/a:** conduce el diagrama funcional.
- **Responsable de seguridad y datos:** revisa el manejo de claves y datos personales.
- **Analista de tecnologías:** conduce la elección de modelos y librerías.
- **Documentador/a y portavoz:** redacta la entrega y responde al comité.

Entrega

Una entrega por equipo en esta Tarea: un PDF con la tabla de modelos y casos de uso, el diagrama numerado, la tabla comparativa, el registro de decisión, las tecnologías elegidas y los nombres de los integrantes con su rol.