

Limpia antes de medir

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · Introducción a modelos generativos y consumo por API

MODALIDAD

Individual, asincrónica.

APRENDIZAJE ESPERADO 4

Implementar un pipeline de preprocesamiento y evaluación básica de texto en Python, aplicando técnicas de limpieza, normalización y métricas iniciales de calidad, de acuerdo con los requisitos de entrada y salida del modelo.

CRITERIOS DE EVALUACIÓN

4.1 Explica los conceptos fundamentales de NLP y evaluación básica de respuestas, considerando token, lema, stopwords, n-gramas, coherencia y relevancia.

4.2 Codifica una rutina en Python para la limpieza de texto, tokenización y normalización sobre un corpus de documentos, de acuerdo con buenas prácticas.

4.3 Calcula métricas básicas de calidad de respuestas generadas, considerando coherencia, relevancia, BLEU y ROUGE, registrando los resultados obtenidos de acuerdo con un protocolo definido.

Contexto

La tienda de decoración Casa Verde (empresa ficticia) usa un modelo de lenguaje para resumir las reseñas de sus clientes. Antes de confiar en los resúmenes quiere dos cosas: que las reseñas lleguen limpias al modelo y una forma de medir si un resumen es bueno.

Insumos

Las cinco reseñas, tal como llegan desde la web:

```
R1: <p>¡¡Me ENCANTÓ la lámpara!! Llegó en 2 días 😍</p>
Muy buena calidad
R2: El envío se demoró 10 días y la caja llegó rota. Pésima experiencia 🤬
https://casaverde.test/pedido/123
R3: <b>Precio justo</b>, pero el color no es igual a la foto...
R4: buenooo, cumple. nada especial. el cojín es más chico de lo que pensé
R5: Excelente atención!!! me cambiaron el producto sin problema. VOLVERÉ A COMPRAR
```

Resumen de referencia, escrito por una persona:

Los clientes valoran la calidad, el precio y la atención, pero reclaman demoras en el envío, productos dañados y diferencias con las fotos.

Dos resúmenes generados por el modelo:

A: Los clientes destacan la calidad, el precio y la buena atención, aunque reportan envíos lentos, cajas dañadas y colores distintos a la foto.

B: Casa Verde es la mejor tienda de decoración de Chile y todos sus clientes están felices con sus compras.

Qué tienes que hacer

- 1. Conceptos (criterio 4.1).** Define token, lema, stopword y n-grama, con un ejemplo tomado de la reseña R1 para cada uno. Explica qué significan coherencia y relevancia al evaluar una respuesta generada.
- 2. Pipeline (criterio 4.2).** En `preprocesamiento.py`, programa funciones reutilizables para cada etapa: quitar HTML, quitar ruido (enlaces, emojis y signos repetidos), normalizar mayúsculas y espacios, tokenizar, quitar stopwords y lematizar, con spaCy o NLTK. Una función `preprocesar(texto)` las encadena. Decide si conservas las tildes y justifícalo.
- 3. Muestra el efecto.** En una tabla, para cada reseña: el texto original, el resultado y la cantidad de tokens antes y después. Lista los cinco bigramas más frecuentes del corpus limpio.
- 4. Mide (criterio 4.3).** Calcula ROUGE-1, ROUGE-L y BLEU de los resúmenes A y B contra la referencia. Si usas la librería `rouge-score`, pásale tu propio tokenizador: el que trae por defecto elimina las letras con tilde y la ñ. Valora además la coherencia y la relevancia de cada resumen de 1 a 3.
- 5. Registra.** Guarda los resultados en `evaluacion.csv` con las columnas `fecha`, `resumen`, `metrica`, `valor`, `herramienta` y `observacion`.
- 6. Interpreta.** En 5 a 8 líneas: ¿qué resumen es mejor? ¿Las métricas automáticas bastan para detectar el problema del resumen B? ¿Qué ajuste le propondrías a Casa Verde?

Entrega

Sube a esta Tarea `preprocesamiento.py`, el notebook o script con las métricas, `evaluacion.csv` y un documento con tus respuestas a los puntos 1, 3 y 6.