

El control de calidad del resumidor

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · Introducción a modelos generativos y consumo por API

MODALIDAD

Grupal, de 4 a 5 personas.

APRENDIZAJE ESPERADO 4

Implementar un pipeline de preprocesamiento y evaluación básica de texto en Python, aplicando técnicas de limpieza, normalización y métricas iniciales de calidad, de acuerdo con los requisitos de entrada y salida del modelo.

CRITERIOS DE EVALUACIÓN

- 4.1 Explica los conceptos fundamentales de NLP y evaluación básica de respuestas, considerando token, lema, stopwords, n-gramas, coherencia y relevancia.
- 4.2 Codifica una rutina en Python para la limpieza de texto, tokenización y normalización sobre un corpus de documentos, de acuerdo con buenas prácticas.
- 4.3 Calcula métricas básicas de calidad de respuestas generadas, considerando coherencia, relevancia, BLEU y ROUGE, registrando los resultados obtenidos de acuerdo con un protocolo definido.

Contexto

La plataforma de soporte de Nube Sur ya resume y clasifica tickets. Durante una semana de piloto, el resumidor procesó tickets reales y el jefe de soporte escribió a mano un resumen de referencia para algunos de ellos.

Problema

Algunos agentes dicen que los resúmenes "a veces inventan cosas" y otros que "a veces no dicen nada". Nadie tiene datos: la decisión de pasar a producción se está tomando por opiniones.

Solución

Un pipeline de evaluación que limpie los tickets, mida la calidad de cada resumen con métricas automáticas y con una pauta humana, registre los resultados según un protocolo y proponga ajustes.

Desarrollo

Insumos: seis tickets del piloto, con el resumen generado y el de referencia.

#	Ticket	Resumen generado	Resumen de referencia
P1	Hola, la app de inventario se cierra cuando escaneo un código de barras con la cámara. Pasa en Android 13. Gracias, Rodrigo	La app de inventario se cierra al escanear códigos de barras en Android 13.	La app de inventario se cierra al escanear un código de barras en Android 13.
P2	No puedo descargar las facturas en PDF desde el portal; el botón muestra "error 500". Urgente, cierre contable hoy.	El usuario tiene un problema con el portal.	El portal devuelve error 500 al descargar facturas en PDF y el usuario las necesita hoy para el cierre contable.
P3	¿Es posible cambiar el correo de notificaciones de la cuenta? El actual es de una persona que ya no trabaja aquí. Enviado desde mi iPhone	El cliente pide cambiar el correo de notificaciones porque el actual es de un ex trabajador.	El cliente quiere cambiar el correo de notificaciones de la cuenta, que pertenece a un ex trabajador.
P4	La sincronización con el ERP falla todas las noches desde el viernes; el log dice "timeout" a las 02:00.	La sincronización con el ERP falla desde el viernes por un corte de luz en el centro de datos.	La sincronización nocturna con el ERP falla por timeout desde el viernes.
P5	Hola!!! el reporte de ventas por región muestra montos duplicados para la región de Valparaíso en septiembre. Adjunto captura.	El reporte de ventas por región duplica los montos de Valparaíso en septiembre.	El reporte de ventas por región muestra montos duplicados de Valparaíso en septiembre.
P6	Buenas tardes. Quisiera saber si el plan Pyme incluye acceso a la API y cuántas llamadas por minuto permite. También si hay descuento anual.	El cliente consulta si el plan Pyme incluye la API, su límite de llamadas por minuto, si hay descuento anual y si incluye soporte telefónico.	El cliente pregunta si el plan Pyme incluye la API, cuántas llamadas por minuto permite y si tiene descuento anual.

- 1. Protocolo (criterio 4.1).** Antes de medir, escriban el protocolo de evaluación: qué miden, con qué métrica o pauta, qué significa cada una (coherencia, relevancia, BLEU y ROUGE) y qué umbral hace que un resumen se marque "revisar".
- 2. Pipeline modular (criterio 4.2).** Programen funciones reutilizables para limpiar, normalizar y tokenizar los tickets, y para vectorizarlos con `CountVectorizer` y `TfidfVectorizer` de scikit-learn. Comparen los cinco términos con más peso de cada vectorización.
- 3. Métricas automáticas (criterio 4.3).** Para cada ticket calculen ROUGE-1, ROUGE-L y BLEU del resumen generado contra la referencia, y la relevancia como similitud coseno entre el ticket y el resumen con TF-IDF.
- 4. Evaluación humana.** Dos integrantes valoran por separado la coherencia y la relevancia de cada resumen de 1 a 3. Después comparan y acuerdan una nota final. Registren en cuántos casos no coincidieron.
- 5. Registro.** Guarden todo en `evaluacion_piloto.csv` según su protocolo.

6. **Ajustes.** Identifiquen los resúmenes que fallan y el tipo de falla (inventa datos, omite información clave, agrega información que no está en el ticket). Propongan al menos **dos ajustes** al resumidor (en el prompt, en la limpieza o en los parámetros), justificados con sus números.
7. **Presentación.** El portavoz presenta la recomendación del equipo: ¿el resumidor pasa a producción, pasa con ajustes o no pasa?

Roles del equipo

Roten los roles respecto del ABPRO anterior:

- **Coordinador/a:** cuida el tiempo y redacta el protocolo con el equipo.
- **Responsable de preprocesamiento:** programa la limpieza y la vectorización.
- **Responsable de métricas:** calcula ROUGE, BLEU y la similitud coseno.
- **Evaluadores/as humanos (2):** aplican la pauta por separado y acuerdan la nota. En equipos de 4, uno de ellos es también el portavoz.
- **Portavoz:** presenta la recomendación.

Entrega

Una entrega por equipo en esta Tarea:

- el notebook o los scripts del pipeline;
- `evaluacion_piloto.csv`;
- un documento con el protocolo, el análisis de fallas, los ajustes propuestos y la recomendación;
- los nombres de los integrantes con su rol.