

Un cliente de API para el resumidor

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · INTRODUCCIÓN A MODELOS GENERATIVOS Y CONSUMO POR API · 21 h

TÉCNICA	TIEMPO ESTIMADO	INDICADORES DE LOGRO
Resolución de problemas	7 h (2 h guiadas + 5 h autónomas)	1.2, 1.3, 2.1, 2.2, 2.3, 3.1, 3.2
APOYOS	PRODUCTO	SE EVALÚA CON
Notebook guiado "Laboratorio de prompts"; Cuatro cápsulas de contenido, una por AE	Diagrama + <code>cliente_ia.py</code> + <code>test_cliente_ia.py</code> + <code>prompts.md</code>	Rúbrica de revisión de la solución (observación) (M2-Instrumento-1.pdf)

APRENDIZAJES ESPERADOS

AE1. ANALIZAR EL ROL DE LOS MODELOS GENERATIVOS EN EL DESARROLLO DE APLICACIONES, DESCRIBIENDO SUS TIPOS, CASOS DE USO, TECNOLOGÍAS ASOCIADAS Y REPRESENTANDO ARQUITECTURAS FUNCIONALES QUE INTEGREN ESTOS MODELOS MEDIANTE APIS.

AE2. UTILIZAR UN MODELO DE IA A TRAVÉS DE API REST UTILIZANDO SOLICITUDES HTTP Y AUTENTICACIÓN, BASÁNDOSE EN LA DOCUMENTACIÓN OFICIAL DE OPENAI Y HUGGING FACE.

AE3. FORMULAR PROMPTS EFECTIVOS PARA MODELOS GENERATIVOS EN ESCENARIOS ZERO-SHOT O FEW-SHOT, CONSIDERANDO LA TAREA SOLICITADA Y LOS PARÁMETROS DE GENERACIÓN DISPONIBLES.

La mesa de ayuda de Nube Sur (empresa ficticia) quiere un resumidor de tickets. Antes de escribir prompts, el equipo necesita dos cosas: saber cómo va a estar armada la aplicación y tener una pieza de código confiable para hablar con el modelo.

Parte A — Arquitectura (AE1). Dibuja el diagrama funcional del resumidor con estos componentes: la aplicación de la mesa de ayuda (cliente), el servidor que expone la API interna, el módulo de preprocesamiento, el modelo de IA externo y una base de datos o *vector store*. Explica en una línea qué hace cada uno y responde: **¿dónde se guarda la clave de la API y por qué no puede estar en el cliente?** Justifica tu arquitectura con dos criterios: escalabilidad, seguridad, costo o mantenimiento.

Parte B — Cliente de API (AE2). Programa en Python el módulo `cliente_ia.py` con una clase `ClienteIA` que:

1. lea la clave y los nombres de modelo desde **variables de entorno**, nunca desde el código;
2. liste los modelos disponibles con una solicitud **GET**;
3. genere texto con una solicitud **POST** al endpoint de chat, con `temperature` y límite de tokens configurables, y devuelva el texto y los tokens usados;
4. obtenga **embeddings** de una lista de textos con una solicitud **POST**;
5. informe los errores HTTP con un mensaje claro;

6. esté documentada con **docstrings**.

Escribe además `test_cliente_ia.py` con **al menos tres pruebas unitarias** que se ejecuten **sin conexión**, simulando la API.

Parte C — El prompt que no sirve (AE3). El equipo probó este prompt y el jefe de soporte lo rechazó:

```
Resume esto: <ticket>
```

Con `temperature` 1,0 y el ticket *"La app móvil se cierra al abrir el historial de pedidos en Android 14; en iOS funciona."* devolvió dos salidas distintas: (a) *"Hay un problema con la app. Se recomienda reinstalarla y actualizar el sistema operativo para solucionar el error de forma definitiva."* y (b) *"App falla."*

1. Diagnostica **tres fallas** del prompt o de sus parámetros: qué indicación falta y qué efecto tuvo en las salidas.
2. Reescribe el prompt como **zero-shot** con rol, tarea, formato y restricciones. Elige `temperature` y límite de tokens y justifica cada uno en una línea.
3. Pruébalo con tu `ClienteIA` sobre ese ticket y sobre este otro: *"No puedo descargar la factura de agosto desde el portal; el botón queda cargando."*

Entrega: el diagrama (imagen o Mermaid), los dos archivos `.py`, la salida de `pytest`, `prompts.md` con el diagnóstico, el prompt corregido y sus dos salidas, y un `README.md` breve. Tu clave **no** puede aparecer en ningún archivo ni captura.

Laboratorio de prompts y métricas

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · INTRODUCCIÓN A MODELOS GENERATIVOS Y CONSUMO POR API · 21 h

TÉCNICA

Análisis de caso + simulación con tablero de puntajes

TIEMPO ESTIMADO

6 h (1,5 h sincrónica + 4,5 h autónomas)

INDICADORES DE LOGRO

3.1, 3.2, 3.3, 4.1, 4.2, 4.3

APOYOS

Video interactivo "Del prompt a la respuesta"

PRODUCTO

Notebook del pipeline + registro de prompts + tabla de métricas

SE EVALÚA CON

Rúbrica de revisión de la solución (observación) (M2-Instrumento-1.pdf); Bitácora de registro de resultados y plan de trabajo (M2-Bitacora.pdf)

APRENDIZAJES ESPERADOS

AE3. FORMULAR PROMPTS EFECTIVOS PARA MODELOS GENERATIVOS EN ESCENARIOS ZERO-SHOT O FEW-SHOT, CONSIDERANDO LA TAREA SOLICITADA Y LOS PARÁMETROS DE GENERACIÓN DISPONIBLES.

AE4. IMPLEMENTAR UN PIPELINE DE PREPROCESAMIENTO Y EVALUACIÓN BÁSICA DE TEXTO EN PYTHON, APLICANDO TÉCNICAS DE LIMPIEZA, NORMALIZACIÓN Y MÉTRICAS INICIALES DE CALIDAD, DE ACUERDO CON LOS REQUISITOS DE ENTRADA Y SALIDA DEL MODELO.

El jefe de soporte de Nube Sur va a elegir **una** configuración para el resumidor y quiere evidencia, no opiniones. Te entrega 5 tickets reales (anonimizados, ficticios para el curso) con el resumen que escribió una persona de su equipo para cada uno. Tu misión es simular la decisión: preparar los tickets, probar estrategias de prompt y medir cuál resume mejor.

- 1. Preprocesa (AE4).** Programa funciones que limpien HTML y firmas, reemplacen correos y enlaces por marcas, normalicen espacios y tokenicen. Explica con un ticket qué cambió.
- 2. Diseña (AE3).** Escribe un prompt **zero-shot** y uno **few-shot** (con dos ejemplos) para resumir un ticket en una oración de máximo 25 palabras.
- 3. Itera (AE3).** Registra al menos tres versiones del prompt con qué cambiaste y qué efecto tuvo. Prueba cada estrategia con `temperature` 0,2 y 0,9.
- 4. Mide (AE4).** Calcula ROUGE-1, ROUGE-L y BLEU de cada resumen contra la referencia, valora coherencia y relevancia de 1 a 3, y registra todo en `resultados.csv`.
- 5. Decide.** Recomienda una configuración en 5 líneas, con números.

Tablero del laboratorio (gamificación): cada participante publica en el LMS su mejor ROUGE-L promedio y la configuración que lo logró. Hay insignias para **"Mejor ROUGE-L"**, **"Prompt más corto con ROUGE-L sobre 0,5"** y **"Mejor bitácora de iteraciones"** (esta la elige el tutor). Lo que puntúa en la nota no es el primer lugar, sino el proceso registrado.

Insumos

id	Ticket (tal como llega)	Resumen de referencia
T1	<p>Hola equipo,</p><p>Desde ayer en la tarde no puedo iniciar sesión en la app de facturación después de cambiar mi contraseña. Me dice "credenciales inválidas" aunque estoy segura de que la escribo bien.</p><p>Saludos,
Marta</p> + firma -- Marta Vidal · Contabilidad · marta.vidal@cliente.test	El usuario no puede iniciar sesión en la app de facturación tras cambiar su contraseña.
T2	Buenas, el reporte mensual de ventas en PDF sale con las tildes rotas (aparece "Compañ±Ãa"). Pasa desde la actualización del lunes. Enviado desde mi teléfono	El reporte mensual de ventas en PDF muestra caracteres rotos desde la actualización del lunes.
T3	URGENTE!!! la API de pagos responde error 504 en el 30% de las llamadas desde las 09:00, afecta a clientes en Chile y Perú. Logs: https://logs.nubesur.test/abc	La API de pagos devuelve error 504 en parte de las llamadas desde las 09:00 en Chile y Perú.
T4	Hola, ¿se puede exportar el listado de clientes a Excel? No encuentro la opción en el panel. Gracias	El usuario pregunta cómo exportar el listado de clientes a Excel desde el panel.
T5	El botón "Guardar" del formulario de proveedores no hace nada en Firefox; en Chrome funciona bien. Probé borrando caché.	El botón Guardar del formulario de proveedores no funciona en Firefox.

Todos los nombres, correos y dominios son ficticios (el dominio `.test` está reservado).