

Instrumento 2 · Proyecto "Asistente de preguntas frecuentes para Nube Sur" (desempeño)

PF1822 · Especialización en Desarrollo con IA

Módulo 2 · MA04576 · INTRODUCCIÓN A MODELOS GENERATIVOS Y CONSUMO POR API · 21 h

APRENDIZAJES ESPERADOS

AE1 · AE2 · AE3 · AE4

DOCUMENTO

M2-Instrumento-2.pdf

SE PUBLICA EN

El LMS del curso

Modalidad: individual, con entrega como repositorio en GitHub (o equivalente) con `README.md`.

Enunciado

La mesa de ayuda de Nube Sur recibe muchas preguntas que ya están respondidas en su lista de preguntas frecuentes (se entregan 8 pares pregunta–respuesta ficticios). Construye un asistente mínimo que, dada una pregunta de un cliente, encuentre la pregunta frecuente más parecida y redacte una respuesta breve basada **solo** en esa respuesta oficial.

- 1. Arquitectura (AE1).** En el README: diagrama de la solución (cliente, servidor, preprocesamiento, modelo, almacén de embeddings), función de cada componente y por qué elegiste esa arquitectura (dos criterios).
- 2. API (AE2).** Reutiliza tu `ClienteIA`: embeddings de las 8 preguntas frecuentes y de la pregunta del cliente; generación de la respuesta. Clave por variable de entorno. Al menos tres pruebas unitarias sin conexión.
- 3. Prompts (AE3).** Un prompt few-shot que obligue a responder solo con la información de la respuesta oficial y a decir "Te derivo con un ejecutivo" cuando no alcance. Compáralo con un zero-shot y registra dos iteraciones.
- 4. Preprocesamiento y evaluación (AE4).** Limpia y normaliza las preguntas antes de calcular embeddings. Para 5 preguntas de prueba con respuesta de referencia, calcula ROUGE-L y BLEU, valora coherencia y relevancia, y registra todo en un CSV.

Insumos: preguntas frecuentes de Nube Sur (ficticias)

#	Pregunta frecuente	Respuesta oficial
F1	¿Cómo recupero mi contraseña?	En la pantalla de ingreso, elige "Olvidé mi contraseña"; te llegará un enlace válido por 30 minutos.
F2	¿Cómo agrego un usuario a mi cuenta?	Un administrador entra a Configuración → Usuarios → Invitar y escribe el correo de la persona.

#	Pregunta frecuente	Respuesta oficial
F3	¿Puedo exportar mis clientes a Excel?	Sí: en Clientes, usa el botón Exportar y elige formato XLSX.
F4	¿Qué navegadores son compatibles?	Las dos últimas versiones de Chrome, Firefox, Edge y Safari.
F5	¿Cómo cambio el plan contratado?	En Facturación → Plan puedes subir de plan en el momento; para bajar, el cambio aplica al mes siguiente.
F6	¿Dónde descargo mis facturas?	En Facturación → Documentos están todas las facturas en PDF.
F7	¿La plataforma tiene API?	Sí, con clave por cuenta; la documentación está en el menú Desarrolladores.
F8	¿Cómo elimino mi cuenta?	Escribe a soporte desde el correo del administrador; la eliminación se confirma en 5 días hábiles.

Preguntas de prueba con respuesta de referencia (para la evaluación del requisito 4):

#	Pregunta del cliente	FAQ esperada	Respuesta de referencia
Q1	olvidé la clave y no puedo entrar!!	F1	Elige "Olvidé mi contraseña" en la pantalla de ingreso y recibirás un enlace válido por 30 minutos.
Q2	Necesito pasar la lista de clientes a una planilla	F3	En Clientes, usa Exportar y elige el formato XLSX.
Q3	¿funciona en safari?	F4	Sí, funciona en las dos últimas versiones de Safari, además de Chrome, Firefox y Edge.
Q4	quiero sumar a mi colega como usuario	F2	Un administrador puede invitarlo desde Configuración → Usuarios → Invitar con su correo.
Q5	¿cuánto cuesta el plan anual?	ninguna	Te derivo con un ejecutivo.

La Q5 no tiene respuesta en las preguntas frecuentes: el asistente debe derivar y no inventar un precio. Es la prueba del prompt del requisito 3.

Pauta de corrección (30 puntos)

Req.	AE	Qué se revisa	Puntos
1	AE1	Diagrama con los cinco componentes y su función	2
1	AE1	Justificación con dos criterios; la clave no está en el cliente	2
2	AE2	Embeddings de preguntas frecuentes y consulta; selección por similitud de coseno	3
2	AE2	Generación de respuesta con <code>clienteIA</code> ; clave por variable de entorno	3
2	AE2	Tres o más pruebas unitarias que pasan sin conexión	3

Req.	AE	Qué se revisa	Puntos
3	AE3	Prompt few-shot con restricción de fuente y frase de derivación	3
3	AE3	Comparación con zero-shot y dos iteraciones registradas con su efecto	3
4	AE4	Limpieza y normalización antes de los embeddings	3
4	AE4	ROUGE-L y BLEU bien calculados para las 5 preguntas	3
4	AE4	Coherencia y relevancia valoradas y CSV completo	2
—	—	README claro: cómo se instala, cómo se ejecuta, qué falta	3
Total			30

Respuesta modelada (núcleo del cálculo de similitud):

```
import math

def coseno(a: list[float], b: list[float]) -> float:
    """Similitud de coseno entre dos vectores: 1 = misma dirección, 0 = sin
    relación."""
    producto = sum(x * y for x, y in zip(a, b))
    return producto / (math.sqrt(sum(x * x for x in a)) * math.sqrt(sum(y * y for y
    in b)))

def pregunta_mas_parecida(consulta: str, preguntas: list[str], cliente) ->
tuple[int, float]:
    """Devuelve el índice de la pregunta frecuente más parecida y su similitud."""
    vectores = cliente.embeddings([limpiar(consulta)] + [limpiar(p) for p in
    preguntas])
    similitudes = [coseno(vectores[0], v) for v in vectores[1:]]
    mejor = max(range(len(similitudes)), key=similitudes.__getitem__)
    return mejor, similitudes[mejor]
```

(Con `limpiar` de `preprocesar.py` de la actividad 2.) Si la similitud máxima es baja, el asistente deriva sin llamar al modelo de generación: ahorra tokens y evita inventar.